Kyrian World · arquitectura actual en AWS (Lambda, Cognito, DynamoDB, Bedrock y S3 Vectors, sin VPC)

Web pública, consultada por ai-api
Open-Meteo (meteorología)
Wikimedia Commons (fotos)
webs de los lugares (vistas previas)

HTTPS

Portátil del desarrollador (SSO)
just index, una ciudad cada vez

embeddings de Titan · PutVectors
tras cada fusión del corpus

Nube de AWS

Región · eu-west-1

Route 53
zona alojada
del dominio
(en esta cuenta)

DNS

alias

Navegador
exportación estática
de Next.js

HTTPS

CloudFront
origen único · TLS
/api/*: sin caché,
reenvía la cabecera
Authorization

por defecto

Bucket S3 (privado, OAC)
frontend estático

/api/*

Certificado ACM
(us-east-1)

AWS WAF (web ACL)
reglas gestionadas:
reputación de IP, comunes
y entradas maliciosas
(consola, no Terraform)

API Gateway · REST, regional
autorizador de Cognito
en cada método
/api/v1/ai/* → STREAM
/api/v1/* → en búfer

STREAM (SSE)

en búfer

valida el JWT

ai-api (Lambda, fuera de VPC)
planificador (streaming SSE)
detalle de tarjetas · trazas admin
RAG · misma imagen que en local

QueryVectors · GetVectors (solo lectura)

S3 Vectors · travel-ai-vectors
índice city-kb · 1024 d · coseno
todas las ciudades,
filtradas por metadatos

InvokeModel · ApplyGuardrail
(rol de la función)

trazas · contadores
diarios de tokens

Tabla DynamoDB
travel-ai-interactions
trazas de turnos y contadores
diarios de tokens · bajo demanda
GSI1 + GSI2 · TTL 90 días

HTTPS vía CloudFront
(dominio público),
token bearer del usuario

inicio de sesión
(código + PKCE)

Grupo de usuarios de Cognito
inicio de sesión gestionado
en auth.kyrian-world.com
Google como IdP social
tokens RS256, JWKS

federación (Google, IdP social)

Google
proveedor de
identidad social

core-api (Lambda, fuera de VPC)
autenticación · usuarios · viajes
lista de acceso
misma imagen que en local

IAM · HTTPS

Tabla DynamoDB travel-ai-core
bajo demanda
PK/SK + GSI1 + GSI2
PITR · protección contra borrado

asume el rol de CI (OIDC)

Raíz de arranque (Terraform)
bucket de estado
proveedor OIDC de GitHub
roles de CI

Servicios regionales

CloudWatch
Logs (14 días) · paneles:
servicio, infraestructura
y registros de acceso

Roles de IAM
uno por función

Bedrock
Claude Haiku 4.5
(perfil de inferencia
entre regiones eu.)
Titan Text Embeddings V2

Bedrock Guardrail
travel-ai-planner
en cada mensaje
del viajero

KMS · clave gestionada
por AWS (aws/lambda)
variables de entorno,
secretos

ECR
imágenes de las funciones
(copiadas de GHCR)

GitHub Actions
OIDC → roles de CI

backend-images.yml
construye y publica

GHCR (ghcr.io)
imágenes del backend

deploy-backend.yml: crane copy (mismo digest) y después terraform apply

CI/CD · backend-images.yml: construye las dos imágenes y las publica en GHCR
deploy-backend.yml: crane copy de GHCR a ECR y terraform apply
deploy.yml (frontend): next build, sincronización con S3 e invalidación de CloudFront
infra/aws/bootstrap: bucket de estado de Terraform, proveedor OIDC de GitHub y roles de CI

Línea continua: petición del usuario · Línea discontinua: inicio de sesión, control y CI/CD
Sin VPC ni servidor de base de datos · coste aproximado: unos 5 € al mes