Kyrian World · arquitectura objetivo de producción en AWS (EKS, Aurora, Bedrock AgentCore y S3 Vectors)

Web pública
Open-Meteo, Wikimedia Commons…

HTTPS

AWS Organizations · una cuenta por entorno

Cuenta de producción

Región · eu-west-1

DNS

Route 53
zona alojada

alias

por defecto

Bucket S3 (privado, OAC)
frontend estático

Navegador
(frontend estático)

HTTPS

CloudFront
frontend y API

/api/*

VPC · 3 zonas de disponibilidad

Zona de disponibilidad a

Zona de disponibilidad b

Zona de disponibilidad c

Subred pública

Application Load Balancer · nodos en las 3 AZ · lo crea el AWS Load Balancer Controller

/api/v1/*

/api/v1/ai/*

NAT gateway
(una: salida mínima)

Subred privada

Amazon EKS

core-api · Deployment + HPA
usuarios · viajes
lista de acceso

HTTP

ai-api · Deployment + HPA
planificador: orquestación
y streaming SSE

InvokeAgentRuntime
(SSE)

SQL

nodos: grupos gestionados o Karpenter
pods repartidos en las 3 AZ
ADOT Collector · EKS Pod Identity

Subred aislada

Aurora
PostgreSQL
escritor

Aurora
PostgreSQL
réplica Multi-AZ

ElastiCache
(opcional)
sesiones, caché

Endpoints de VPC · interfaz (PrivateLink) en cada AZ y gateway para S3
bedrock-runtime · bedrock-agentcore · ecr · secretsmanager · logs · monitoring · sts
el tráfico hacia los servicios de AWS no sale por la NAT

IA generativa · Amazon Bedrock

AWS Lambda: herramientas
search_places, get_place,
get_weather… (o servicios
internos en EKS)

invoca

AgentCore Gateway
herramientas por MCP

MCP

Bedrock AgentCore
Runtime · agente Kiri

InvokeModel
ApplyGuardrail
QueryVectors

Modelos y conocimiento

Amazon Bedrock
Claude Haiku 4.5
(perfil de inferencia UE)
Titan Text Embeddings V2

Bedrock Guardrails
en cada mensaje

OpenSearch Serverless
opcional: búsqueda
híbrida (> ~50 000 docs)

S3 Vectors
índice city-kb
1024 d · coseno

PutVectors

AWS WAF (Terraform)
reglas gestionadas
límite por usuario

AWS Shield
Standard

ACM
certificados TLS

Canal de datos del corpus (RAG)

EventBridge Scheduler
(periódico)

Step Functions
orquesta el canal

Construcción del corpus
(tarea ECS Fargate)

Puerta de calidad
(Lambda)

Indexación (Lambda)
embeddings Titan

Seguridad y operación

Cognito
(IdP: Google)

Secrets
Manager

KMS · claves
del cliente

IAM · Pod
Identity / IRSA

CloudWatch
Container Insights

X-Ray · ADOT
(OpenTelemetry)

Alarmas de
CloudWatch → SNS

AWS Budgets
alertas de coste

ECR · escaneo
de imágenes

inicio de sesión
(código + PKCE)

federación

Google
(IdP social)

Cuenta de desarrollo
mismo diseño, menor tamaño

Cuenta de preproducción
mismo diseño, menor tamaño

Cuenta de gestión
Organizations, SCP, IAM Identity Center

OIDC · Helm

OIDC

OIDC

GitHub Actions

CI/CD · GitHub Actions asume por OIDC un rol de despliegue en cada cuenta · Terraform con un estado por cuenta · despliegue en EKS con Helm
imágenes construidas una vez, escaneadas en ECR y promovidas por digest: desarrollo → preproducción → producción

Línea continua: petición del usuario · Línea discontinua: control, CI/CD y datos · Aurora PostgreSQL sustituye a DynamoDB para usuarios, viajes y lista de acceso
Desarrollo local: clúster kind con los mismos espacios de nombres y políticas de red